APRENDIZADO DE MÁQUINA

Da teoria à prática: construindo um modelo de aprendizado de máquina

Até agora exploramos os **fundamentos teóricos** do aprendizado de máquina. A partir de agora, vamos ver esses conceitos ganharem vida em um **problema real de negócio** — com dados reais, código real e decisões reais.

Prepare-se para acompanhar a construção completa de um modelo de previsão de **churn de clientes**, do início ao fim.

CONTEXTO DE NEGÓCIO

O problema de churn de clientes

O que é churn?

Churn é quando um cliente **cancela o serviço** ou deixa de comprar da empresa. Em telecomunicações, isso acontece o tempo todo — e cada cancelamento representa **perda direta de receita**.

Por que prever?

Se soubermos **antes** quais clientes estão propensos a cancelar, podemos agir com:

- Ofertas e descontos personalizados
- Melhoria no atendimento
- Campanhas de fidelização dirigidas

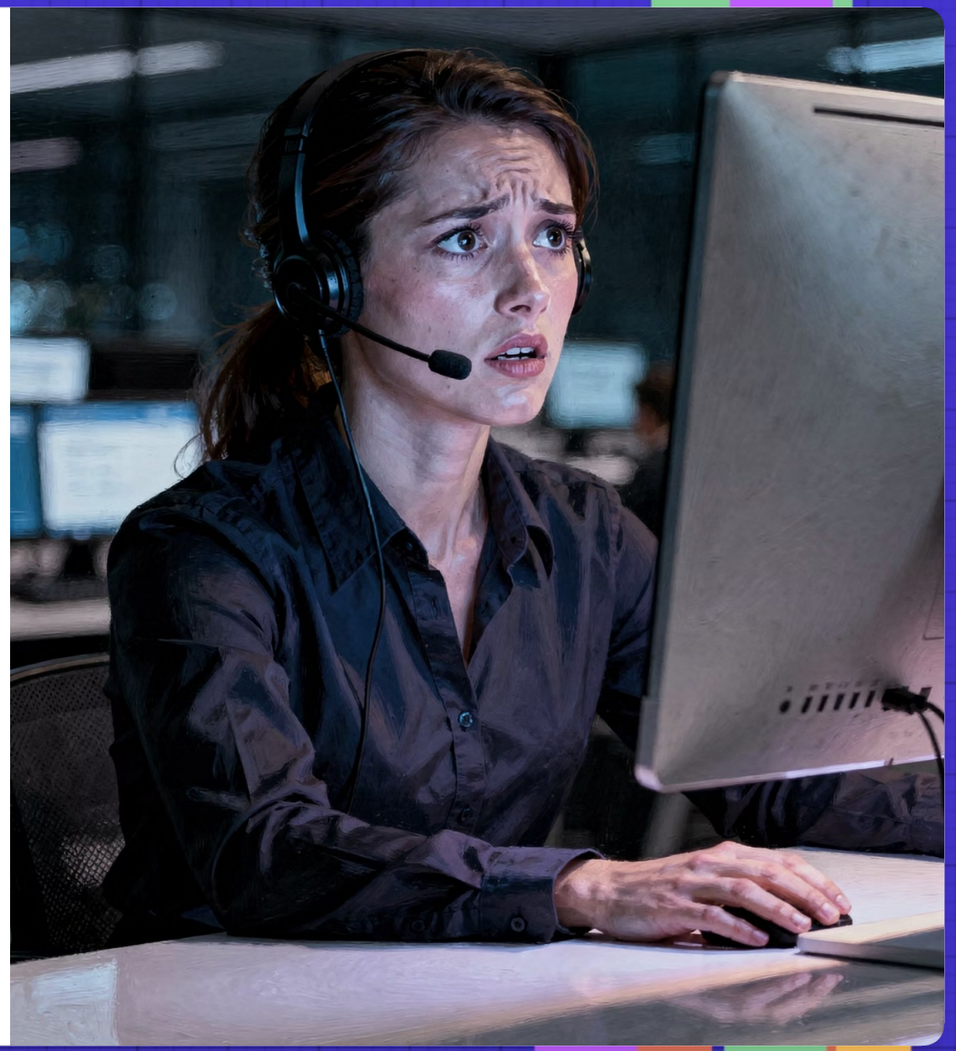

A PERGUNTA CENTRAL

Qual pergunta queremos responder?

🎯 Pergunta de negócio

"Quais clientes têm maior probabilidade de cancelar o serviço nos próximos meses?"

Essa pergunta parece simples, mas carrega toda a inteligência do problema. Para respondê-la de forma escalável — analisando **milhares de clientes ao mesmo tempo** — precisamos transformá-la em um problema que uma máquina possa resolver.

→ **Pergunta de negócio**

Quem vai cancelar?

→ **Problema de dados**

Quais padrões indicam cancelamento?

→ **Problema de ML**

Classificar clientes: vai cancelar ou não?

TRADUÇÃO PARA IA

Transformando o problema de negócio em problema de dados

Para que uma máquina aprenda a identificar clientes em risco, precisamos definir com clareza **o que queremos prever**. No nosso caso:

Variável alvo

Churn = **Sim** ou **Não**

Tipo de problema

Classificação binária: duas classes possíveis

O modelo estima a probabilidade de cancelamento para cada cliente, retornando um valor entre 0 e 1.

Essa probabilidade pode ser convertida em uma classificação binária (Sim/Não) por meio de um limiar de decisão.

P(churn = 1 | dados do cliente) = 0.82

Temos 82% de chance de cancelamento.

Depois podemos aplicar um **threshold** (0.5), probabilidades acima cancelarão (Sim), abaixo não cancelarão (Não).

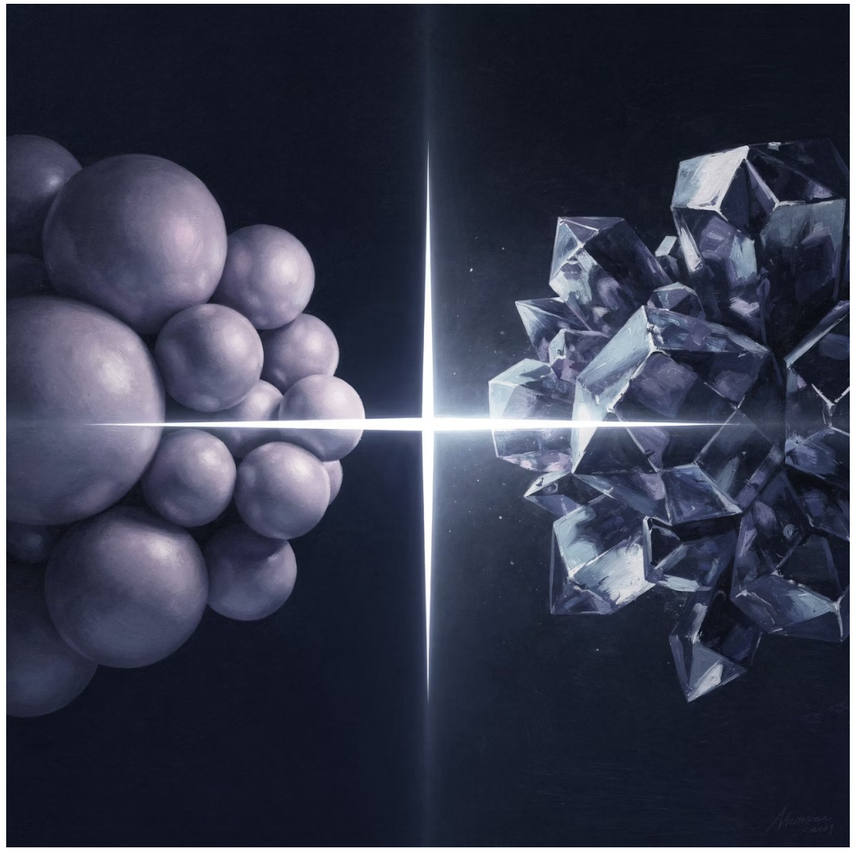

OS DADOS

O dataset de clientes

Cada **linha** do dataset representa um cliente da empresa de telecomunicações. Cada **coluna** representa uma característica desse cliente — informações que o modelo usará para aprender padrões de cancelamento.

Tempo de contrato

Há quantos meses o cliente está na empresa

Tipo de internet

DSL, Fibra óptica ou sem internet

Valor da mensalidade

Quanto o cliente paga por mês

Tipo de contrato

Mensal, anual ou bienal

Forma de pagamento

Boleto, cartão, débito automático

ESTRUTURA DOS DADOS

O que existe dentro dos dados

🔤 Variáveis Categóricas

Representam **categorias ou grupos**. Não têm ordem numérica natural.

- Tipo de contrato (Mensal / Anual)
- Método de pagamento
- Possui serviço de streaming?

🔢 Variáveis Numéricas

Representam **quantidades mensuráveis**. Permitem comparações e cálculos diretos.

- Valor da mensalidade
- Tempo de contrato (meses)
- Total faturado até o momento

O modelo aprende padrões em ambos os tipos de variável para fazer previsões precisas.

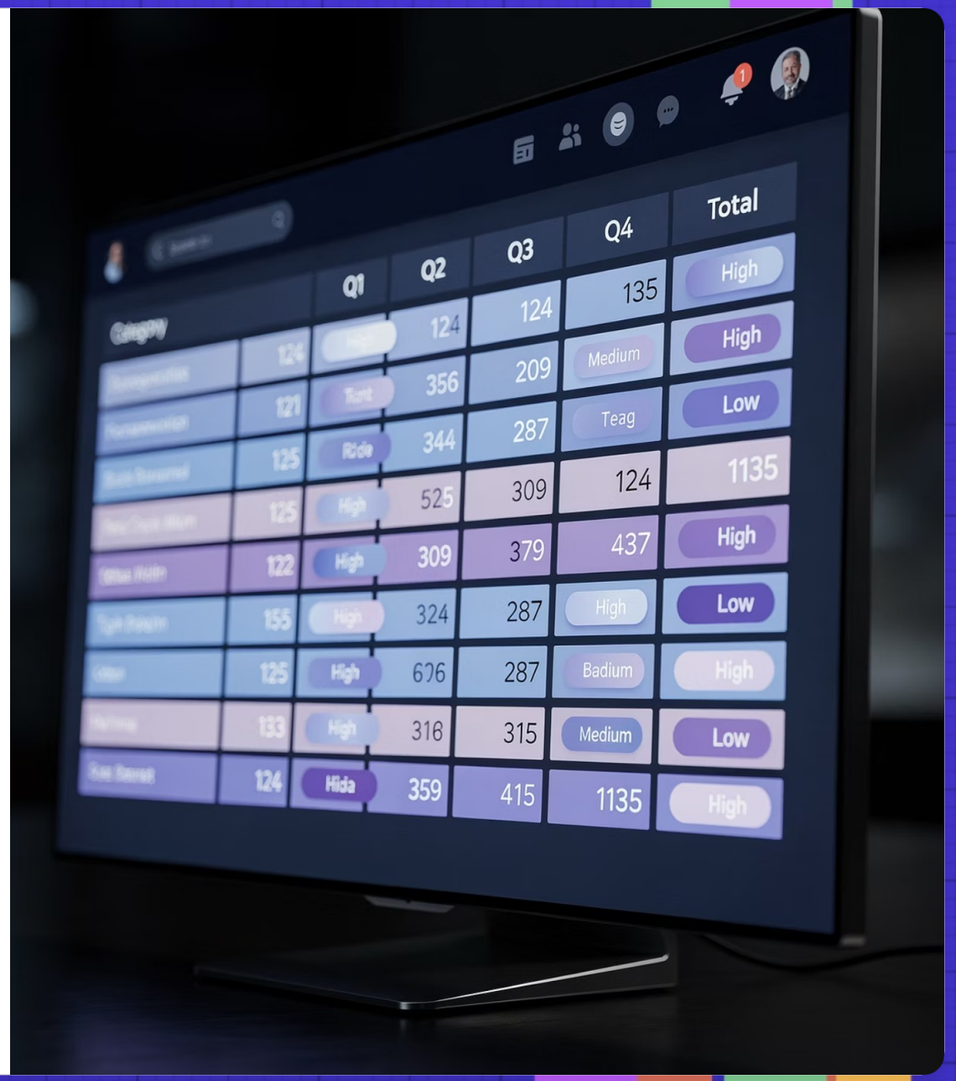

VARIÁVEL ALVO

O que queremos prever

Em machine learning, chamamos de **variável alvo** (ou *target*) aquela que o modelo deve aprender a prever. É a resposta que buscamos.

No nosso problema: A variável alvo é **Churn**, que pode assumir dois valores: **Yes** (cancelou) ou **No** (permaneceu).

O modelo aprenderá a associar os **dados de entrada** (variáveis do cliente) com esse resultado, para prever o comportamento de novos clientes.

Churn = No ✅	Churn = Yes ❌
Cliente permanece ativo. Empresa retém receita.	Cliente cancela. Empresa perde receita recorrente.

FLUXO COMPLETO

Como um modelo de ML é construído

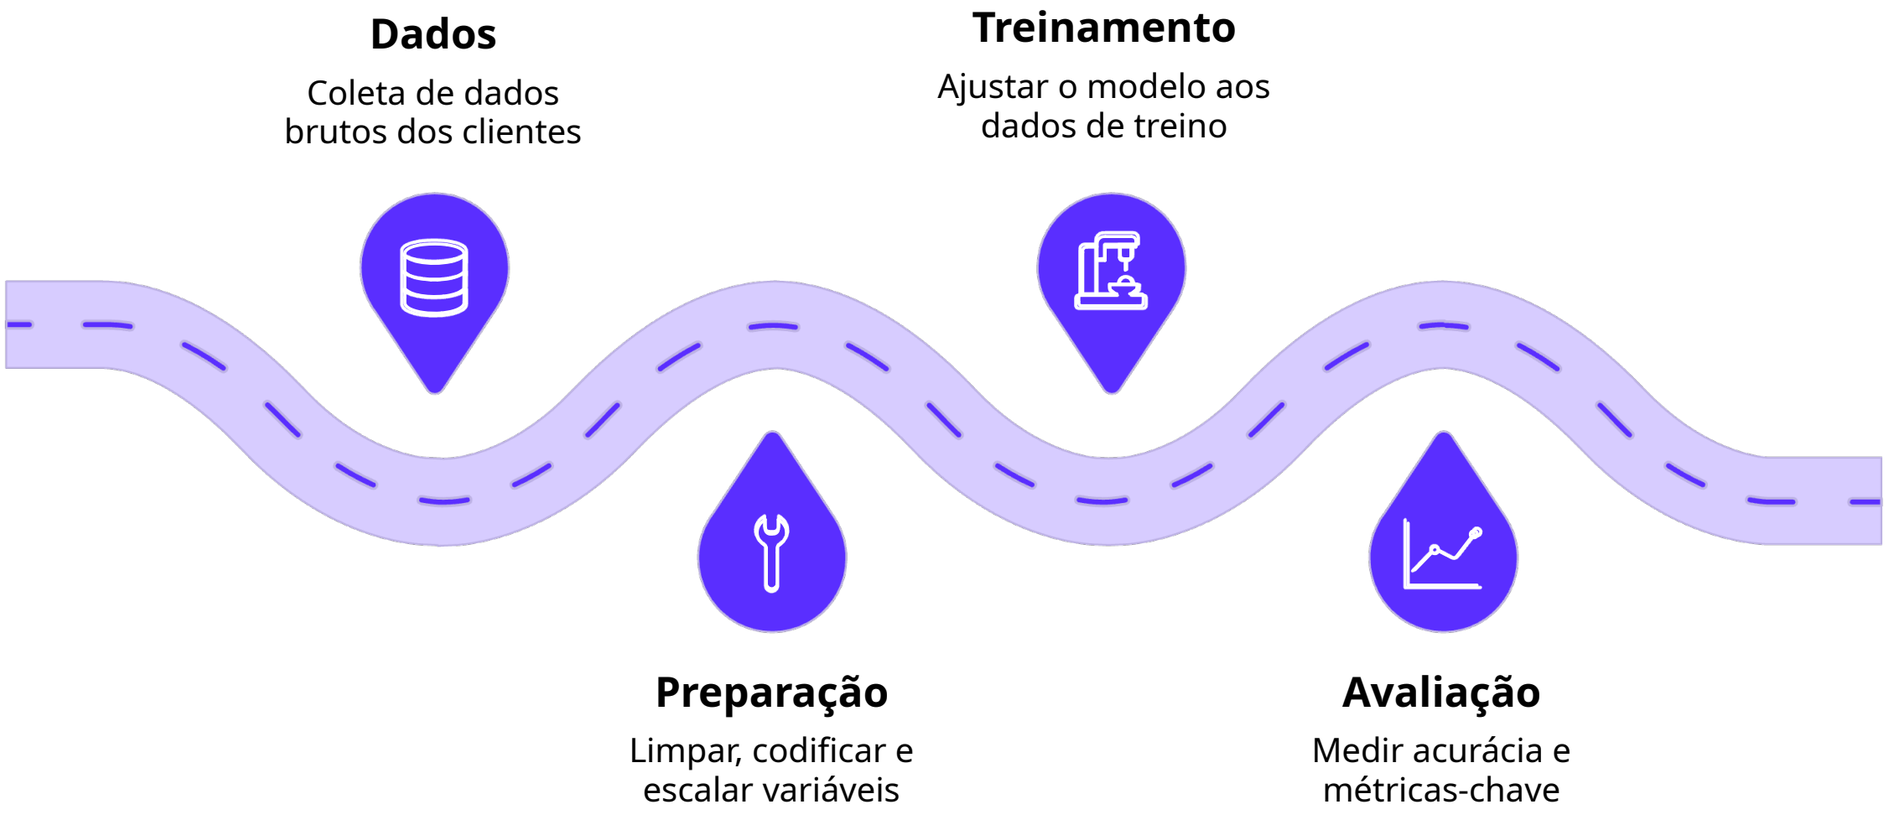

Esse fluxo é a **espinha dorsal** de qualquer projeto de machine learning. Cada etapa é essencial: dados mal preparados comprometem o treinamento; modelos sem avaliação adequada geram decisões equivocadas. Seguiremos exatamente esse pipeline no nosso notebook.

METODOLOGIA

Por que dividimos os dados

🏋 Dados de Treino (~80%)

Usados para o modelo **aprender os padrões**. É como estudar com o gabarito em mãos — o modelo ajusta seus parâmetros com base nesses exemplos.

🧪 Dados de Teste (~20%)

Reservados para **avaliar o desempenho** do modelo em dados nunca vistos. Simulam clientes reais do futuro.

Se o modelo só fosse avaliado nos dados de treino, poderíamos apenas **memorizar** as respostas — sem aprender nada de verdade. A divisão garante que testamos a **generalização**.

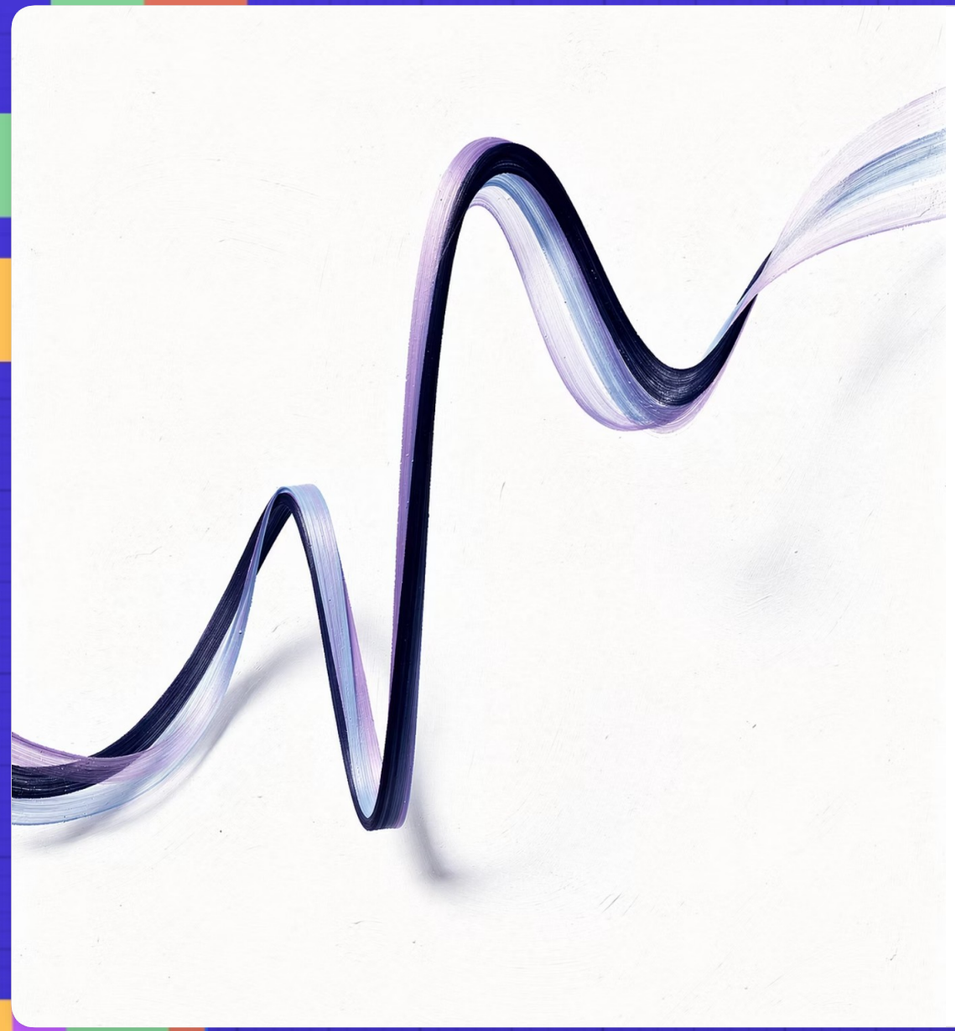

ESCOLHA DO MODELO

Qual modelo vamos usar

Regressão Logística

Apesar do nome sugerir "regressão", a **Regressão Logística** é um dos algoritmos de **classificação** mais utilizados em ciência de dados. Ela estima a *probabilidade* de um evento ocorrer.

✅ Vantagens

- Simples e interpretável
- Treinamento rápido
- Ótimo ponto de partida

📌 Saída

Probabilidade entre **0 e 1**. Ex: P(Churn) = 0.82 → alto risco de cancelamento

TREINAMENTO

O que acontece durante o treinamento

O treinamento é o coração do processo. O modelo **analisa os exemplos de treino**, faz previsões iniciais (geralmente erradas), e ajusta seus parâmetros internos para **reduzir o erro** progressivamente.

Modelo recebe os dados de treino

Cada cliente com suas variáveis e o resultado real (Churn: Yes/No)

Faz uma previsão inicial

Baseada nos parâmetros atuais — geralmente incorreta no início

Calcula o erro

Compara previsão com o resultado real e mede o quanto errou

Ajusta os parâmetros

Modifica pesos internos para reduzir o erro — isso é o **aprendizado**

AVALIAÇÃO

Como avaliamos o desempenho

Métricas de Avaliação

Após o treinamento, usamos os **dados de teste** para medir se o modelo funciona bem em dados novos.

Acurácia (Accuracy)

Proporção de previsões corretas sobre o total. Ex: 82% das previsões foram corretas.

Matriz de Confusão

Tabela que mostra acertos e erros por classe: Verdadeiros/Falsos Positivos e Negativos.

	Previsto: No	**Previsto: Yes**
Real: No	✅ Verdadeiro Negativo	❌ Falso Positivo
Real: Yes	❌ Falso Negativo	✅ Verdadeiro Positivo

A matriz de confusão revela não apenas quantos acertos o modelo teve, mas *onde* ele erra — essencial para problemas de negócio.

CONCEITO-CHAVE

O que significa aprender de verdade

> **Generalização** é a capacidade do modelo de aplicar o que aprendeu nos dados de treino para fazer previsões corretas em *dados novos, nunca vistos antes*.

❌ Memorização

O modelo decora as respostas do treino, mas **falha completamente** em novos dados. Parece ótimo no treino, péssimo na prática.

✅ Generalização

O modelo identifica **padrões verdadeiros** nos dados. Funciona bem tanto no treino quanto em dados novos — esse é o objetivo real.

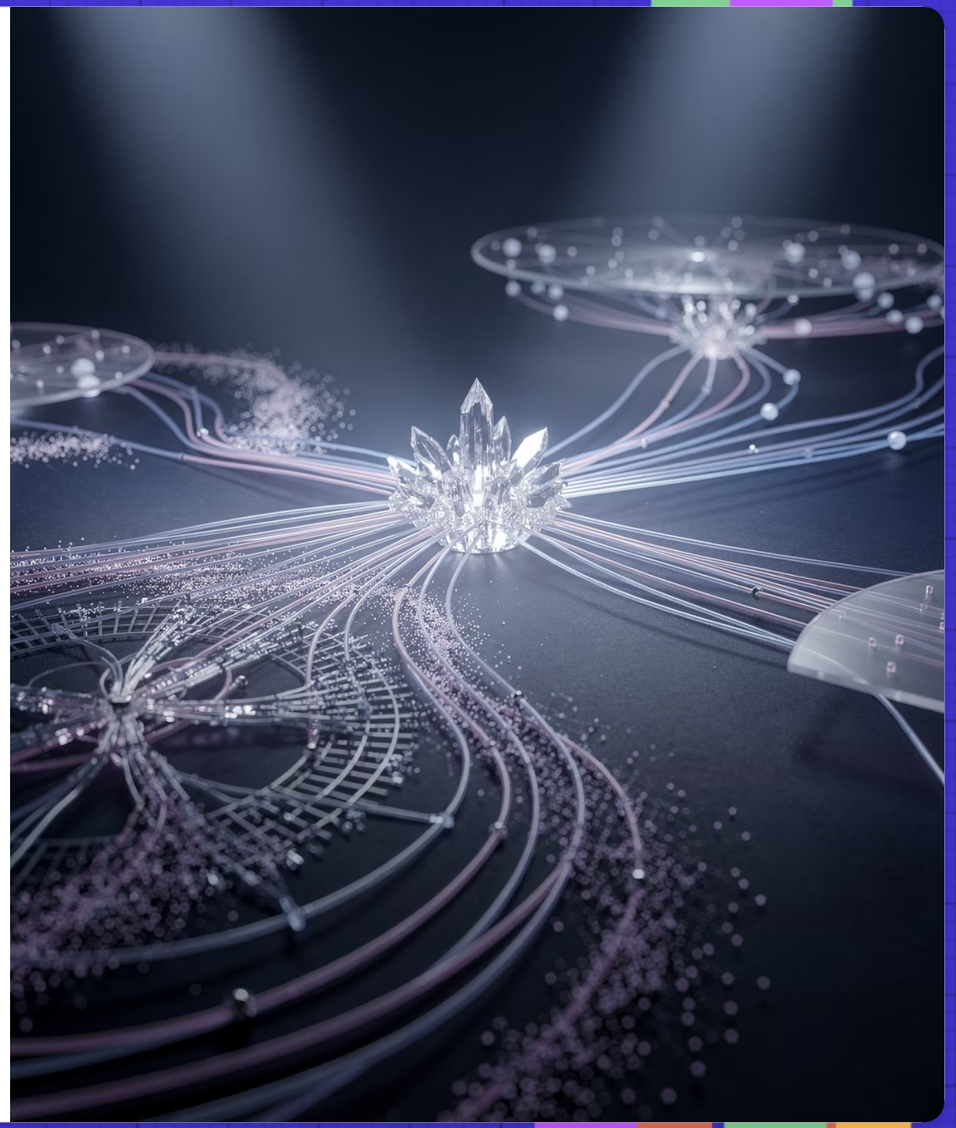

DESAFIO CENTRAL

Quando o modelo aprende demais

Overfitting acontece quando o modelo se ajusta tão perfeitamente aos dados de treino que começa a aprender até o *ruído* e as *exceções* dos dados — perdendo a capacidade de generalizar.

No treino

Acurácia altíssima — parece perfeito

No teste

Acurácia cai bruscamente — modelo inútil

Analogia: Um aluno que decora o gabarito da prova vai bem nela, mas não aprendeu o conteúdo para uma prova diferente.

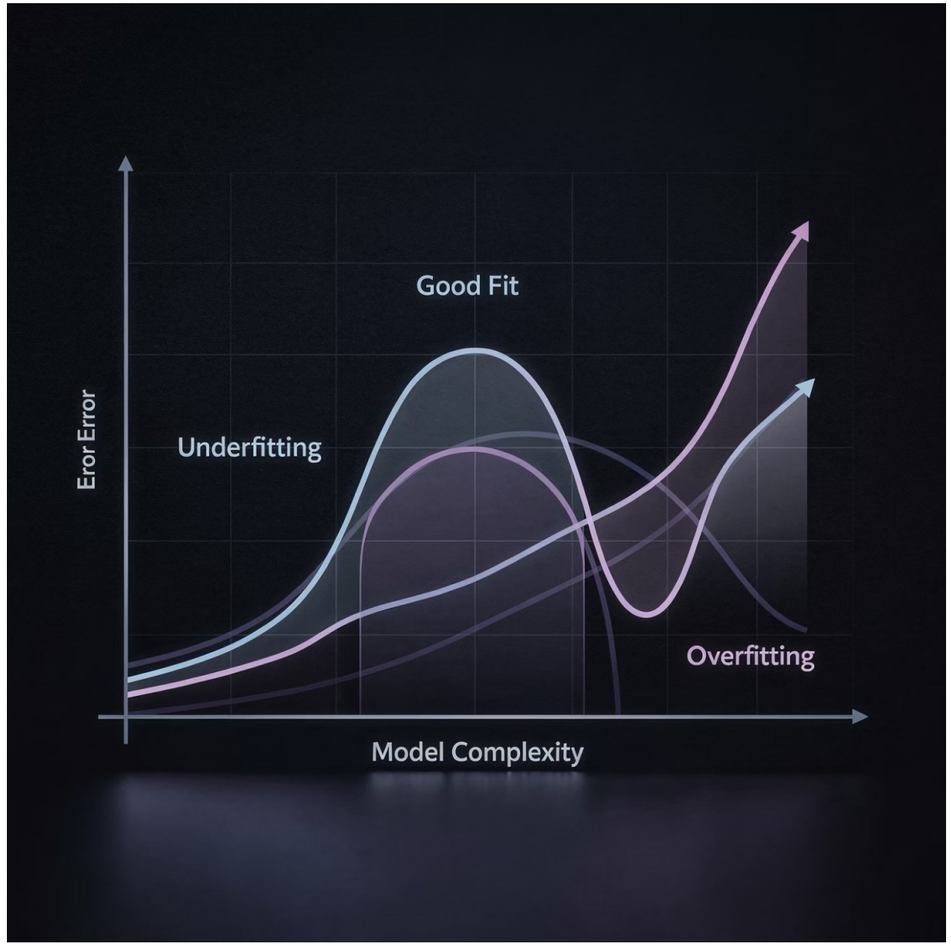

MÃOS À OBRA

O que vamos fazer agora

Chegou a hora de colocar tudo isso em prática. Vamos acompanhar juntos, **passo a passo**, a construção de um modelo de ML real no notebook:

1. Explorar o dataset

Entender os dados, visualizar distribuições e identificar padrões iniciais de churn

2. Preparar os dados

Tratar valores ausentes, codificar variáveis categóricas e normalizar os dados

3. Treinar o modelo

Aplicar Regressão Logística nos dados de treino e ajustar os parâmetros

4. Avaliar resultados

Calcular acurácia, interpretar a matriz de confusão e discutir o desempenho

💻 **Abra o notebook agora.** Vamos executar cada célula juntos e discutir o que acontece em cada etapa.